Escalable

Es muy difícil predecir el alcance y uso que tendrá una API una vez lanzada.
La escalabilidad en una API se refiere a que debe de estar preparada para manejar un incremento del tráfico y seguir proporcionando sus servicios sin que haya una disminución de su desempeño.
Pero al mismo tiempo no debería estar ocupando recursos si no los necesita.

Arquitectura monolítica

Contempla tener toda nuestra Api en un solo servidor, como una misma app.
El código mismo de la API, la base de datos, la autenticación, etc.

Arquitectura en capas

Contempla dividir el Api en diferentes módulos que se comunicarán unos con otros.
La misma arquitectura REST contempla el modelo Cliente-Servidor.
Deberemos considerar dividir el Api en Apis mas pequeñas que se hablen entre si.
Es mas fácil escalar un sistema distribuido, que uno monolítico.
ya que podemos trabajar independientemente en cada módulo o subsistema, si la Api crece.